

Résolution numérique des systèmes linéaires

Introduction

On se propose de résoudre les systèmes linéaires de la forme:

$$(SL) : \begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n = b_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \dots + a_{nn}x_n = b_n \end{cases}$$

qui s'écrit sous
forme matricielle:

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & & a_{2n} \\ \vdots & & \ddots & \\ a_{n1} & a_{n2} & & a_{nn} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix}$$

Ou encore $AX = b; \quad A \in \text{Mat}_n(\mathbb{R})$
 $b, X \in \mathbb{R}^n$

(SL) admet de solutions $\iff A$ est **inversible**

$$\iff \det(A) \neq 0.$$

Utilisant la méthode de Cramer, chaque composante x_k de la solution X est donnée par:

$$x_k = \frac{\det(A_k)}{\det(A)} = \frac{\Delta_k}{\Delta}, \quad 1 \leq k \leq n$$

où A_k est la matrice obtenue en remplaçant la $k^{\text{ième}}$ colonne de A par le second membre b .

Lorsque n est "assez grand ", le calcul de $\det(A)$ nécessite de l'ordre de $n.n!$ opérations élémentaires.

⇒ le calcul de la solution X par la méthode de Cramer nécessite alors de l'ordre de $n^2.n!$ opérations élémentaires.

Par exemple, pour trouver la solution d'un système linéaire par la méthode de Cramer en utilisant un ordinateur qui effectue 10^6 opérations élémentaires par seconde, il faut pour l'ordre:

$n=18$ $\longrightarrow$ 200 ans de calcul

$n=50$ $\longrightarrow$ $2,4 \cdot 10^{54}$ ans de calcul !!!!!!!

D'où la nécessité de développer des méthodes de résolution des systèmes linéaires plus **économiques**; et on verra dans la suite que ces même systèmes seront résolus, avec les méthodes qui seront présentées, presque en **temps réel**.

On distingue deux types de méthodes de résolution:

- 1)** Les **méthodes directes** qui permettent d'atteindre en un nombre fini d'opérations la solution du problème.
- 2)** Les **méthodes itératives** qui construisent une suite de vecteurs qui convergent vers la solution.

Le choix de la méthode dépend de la structure de la matrice et de la nature du problème à résoudre.

Partie I: Rappels d'algèbre linéaire

1. Norme matricielle
2. Rayon spectral
3. Norme induite
4. Conditionnement de matrice
5. Effet de perturbation

Définition (norme matricielle)

On appelle **norme matricielle** une norme définie sur $M_n(C)$ qui est compatible avec la multiplication des matrices.

C'est-à-dire: $\|\cdot\| : M_n(C) \rightarrow \mathbb{R}^+$

$$A \mapsto \|A\|$$

telles que:

$$\forall A, B \in M_n(C) \quad \text{et} \quad \forall \lambda \in C :$$

- **Séparation** : $\|A\| = 0 \Leftrightarrow A = (0)$.
- **Homogénéité** : $\|\lambda A\| = |\lambda| \|A\|$.
- **Inégalité triangulaire** : $\|A + B\| \leq \|A\| + \|B\|$.
- $\|AB\| \leq \|A\| \|B\|$.

Exemple de norme matricielle

Norme de Frobenius:

$$\forall A \in M_n(C), \quad \|A\|_F = \sqrt{\sum_{i=1}^n \sum_{j=1}^n a_{ij}^2} = \sqrt{\text{tr}({}^tAA)}.$$

Définition (rayon spectral)

Soit $A \in M_n(\mathbb{R})$ et $\lambda_i, 1 \leq i \leq n$, les n valeurs propres de A (comptées avec leur ordre de multiplicité).

On appelle **rayon spectral** de A , le réel positif :

$$\rho(A) = \max_{1 \leq i \leq n} |\lambda_i|.$$

Remarque :

$$\rho(A) = \max_{1 \leq i \leq n} \left\{ |\lambda_i|; \quad \lambda_i \text{ valeur propre de } A \right\}$$

n'est pas une norme.

Normes subordonnées

Définition (norme induite ou subordonnée)

Soit $\|\cdot\|_v$ une norme vectorielle définie sur $\mathbb{C}^n$ et $A \in M_n(\mathbb{C})$.

On appelle norme matricielle **induite** ou **subordonnée**, la norme matricielle définie par:

$$\|A\| = \max_{x \in \mathbb{C}^n, x \neq 0} \frac{\|Ax\|_v}{\|x\|_v}$$


Remarque : Toute norme matricielle subordonnée $\|\cdot\|$ vérifie

$$1) \forall x \in \mathbb{C}^n, \forall A \in M_n(\mathbb{C}), \quad \|Ax\|_v \leq \|A\| \|x\|_v,$$

$$2) \|I_n\| = 1.$$

Exemples de normes induites

1) Soit la norme vectorielle $\|\cdot\|_1$ (norme indice 1):



$$\forall x = (x_i)_{1 \leq i \leq n} \in \mathbb{R}^n, \quad \|x\|_1 = \sum_{i=1}^n |x_i|$$

cette norme induit pour tout $A = (a_{ij})_{1 \leq i, j \leq n} \in M_n(\mathbb{R})$

la norme:

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|.$$

2) Soit la norme vectorielle $\|\cdot\|_2$ (norme euclidienne):


$$\forall x = (x_{1 \leq i \leq n}) \in \mathbb{R}^n, \quad \|x\|_2 = \left(\sum_{i=1}^n |x_i|^2 \right)^{1/2}$$


cette norme induit pour tout $A = (a_{ij})_{1 \leq i, j \leq n} \in M_n(\mathbb{R})$

la norme:

$$\|A\|_2 = \sqrt{\rho({}^t A A)} = \|{}^t A\|_2.$$

3) Soit la norme vectorielle $\|\cdot\|_\infty$ (norme indice l'infini):

$$\forall x = (x_i)_{1 \leq i \leq n} \in \mathbb{R}^n, \quad \|x\|_\infty = \max_{1 \leq i \leq n} |x_i|$$



cette norme induit pour tout $A = (a_{ij})_{1 \leq i, j \leq n} \in M_n(\mathbb{R})$

la norme:

$$\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| = \|{}^t A\|_1.$$

Exemple d'une norme matricielle non subordonnée

La norme matricielle $\|\cdot\|$ définie pour tout $n \geq 2$ par:

$$\forall A = (a_{ij})_{1 \leq i, j \leq n} \in M_n(\mathbb{R}), \quad \|A\| = \left(\sum_{i,j=1}^n |a_{i,j}|^2 \right)^{1/2}$$

n'est pas une norme matricielle subordonnée, puisque

$$\|I\| = \sqrt{n} \neq 1.$$

Conditionnement d'une matrice

Définition

Soit $\|\cdot\|$ une norme matricielle **subordonnée** et A une matrice **invertible**. Le nombre:

$$\text{cond}(A) = \|A\| \|A^{-1}\|$$

est appelé le **conditionnement** de A relativement à $\|\cdot\|$.

En pratique, on considère les conditionnements d'indice p :

$$\text{cond}_p(A) = \|A\|_p \|A^{-1}\|_p \quad \text{où } p = 1, 2, \infty$$

Propriétés

Soit $A, B \in M_n(\mathbb{R})$ inversibles et $\alpha \in \mathbb{R} \setminus \{0\}$.

Alors on a :

$$(1) \quad \text{cond}(A) \geq 1 \quad \text{et} \quad \text{cond}(I) = 1.$$

$$(2) \quad \text{cond}(\alpha A) = \text{cond}(A).$$

$$(3) \quad \text{cond}(A) = \text{cond}(A^{-1}).$$

$$(4) \quad \text{cond}(AB) \leq \text{cond}(A)\text{cond}(B).$$

Caractérisation du conditionnement : pour la norme 2

Théorème

On munit $\mathbb{R}^n$ de la norme euclidienne $\|\cdot\|_2$

et $M_n(\mathbb{R})$ de la norme induite associée.

Soit $A \in M_n(\mathbb{R})$ une matrice symétrique et inversible.

Alors on a :

$$\text{cond}_2(A) = \frac{\lambda_{\max}}{\lambda_{\min}}$$

où :

$$\lambda_{\max} = \max_{1 \leq i \leq n} \{|\lambda|; \lambda \text{ valeur propre de } A\}$$

$$\lambda_{\min} = \min_{1 \leq i \leq n} \{|\lambda|; \lambda \text{ valeur propre de } A\}$$

Une matrice A est “ **bien conditionnée** ” vis-à-vis de la résolution des systèmes linéaires si une “petite” perturbation de A ou du second membre b engendre une “petite” perturbation de la solution du système linéaire $Ax=b$.



Si $\text{cond}(A) \approx 1$, on dit que A est **bien conditionnée**.
et on parle de **stabilité** du système linéaire.

des erreurs sur les données induisent des erreurs de même ordre de grandeur sur la solution.

Majoration de l'erreur relative : pour une perturbation sur le second membre

Soit A une matrice inversible de $M_n(\mathbb{R})$ et $b \in \mathbb{R}^n \setminus \{0\}$.
On munit $\mathbb{R}^n$ d'une norme et $M_n(\mathbb{R})$ de la norme induite.

Proposition

Si $\tilde{x}$ est solution de $Ax = b$
et $\tilde{x} + \delta\tilde{x}$ est solution de $Ax = (b + \delta b)$, pour $\delta b \in \mathbb{R}^n$.
Alors on a :

$$\frac{\|\delta\tilde{x}\|}{\|\tilde{x}\|} \leq \text{cond}(A) \frac{\|\delta b\|}{\|b\|}.$$

Majoration de l'erreur relative : pour une perturbation sur la matrice

Soit A une matrice inversible de $M_n(\mathbb{R})$ et $b \in \mathbb{R}^n \setminus \{0\}$.
On munit $\mathbb{R}^n$ d'une norme et $M_n(\mathbb{R})$ de la norme induite.

Proposition

Si $\tilde{x}$ est solution de $Ax = b$,
et $\tilde{x} + \delta\tilde{x}$ est solution de $(A + \delta A)x = b$, pour $\delta A \in M_n(\mathbb{R})$.
Alors on a :

$$\frac{\|\delta\tilde{x}\|}{\|\tilde{x} + \delta\tilde{x}\|} \leq \text{cond}(A) \frac{\|\delta A\|}{\|A\|}.$$

Majoration de l'erreur relative : pour une perturbation sur la matrice et le second membre

On peut en fait majorer l'erreur relative dans le cas où l'on commet à la fois une erreur sur A et une erreur sur b . D'où le Théorème:

Proposition

Soit $A \in M_n(\mathbb{R})$ une matrice inversible et $b \in \mathbb{R}^n \setminus \{0\}$.

On munit $\mathbb{R}^n$ d'une norme et $M_n(\mathbb{R})$ de la norme induite.

Soient $\delta A \in M_n(\mathbb{R})$ et $\delta b \in \mathbb{R}^n$. Si $\tilde{x}$ est solution de $Ax = b$, et $\tilde{x} + \delta \tilde{x}$ est solution de $(A + \delta A)x = (b + \delta b)$.

Alors on a :

$$\frac{\|\delta \tilde{x}\|}{\|\tilde{x}\|} \leq \frac{\text{cond}(A)}{1 - \|\delta A\| \|A^{-1}\|} \left(\frac{\|\delta b\|}{\|b\|} + \frac{\|\delta A\|}{\|A\|} \right).$$

Cette majoration est *optimale*.

Partie II : Méthodes directes

1. Principe des méthodes directes
2. Méthode de Gauss
3. Factorisation LU
4. Méthode de Cholesky

Principe des méthodes directes

Le principe de ces méthodes revient à déterminer une matrice M inversible telle que MA soit triangulaire supérieure. On résout alors le système $MAX=Mb$.

En posant $MA=B$ et $Mb=c$, La solution du système $BX=c$ est donnée par la méthode de remontée, c'est à dire si:

$X = (x_i)_{i=1,\dots,n}$; $c = (c_i)_{i=1,\dots,n}$ et $B = (b_{ij})_{1 \leq i,j \leq n}$, alors le système

$$BX = c \quad \text{s'écrit} \quad \left\{ \begin{array}{l} b_{11}x_1 + b_{12}x_2 + \dots + b_{1n}x_n = c_1 \\ \vdots \\ b_{n-1,n-1}x_{n-1} + b_{n-1,n}x_n = c_{n-1} \\ b_{nn}x_n = c_n \end{array} \right.$$

on commence par calculer x_n , ensuite x_{n-1} , ensuite..., x_1 .

Méthode de Gauss

- On calcule la matrice $M.A$ par récurrence: on multiplie A par des matrices **élémentaires** jusqu'à obtenir au bout de $(n-1)$ étapes une matrice triangulaire supérieure.
- On pose $A^{(1)} = A$. Comme $A^{(1)}$ est inversible donc la première colonne de $A^{(1)}$ contient au moins un élément non nul $a_{i,1}^{(1)}$ qui est appelé **premier pivot** de l'élimination.
 - * Si $a_{1,1}^{(1)} = 0$ on fait une permutation des équations du système linéaire.

Ceci revient à multiplier à gauche la matrice $A^{(1)}$ par la matrice de transposition $T^{(1,i)}$, où $T^{(i,j)}$ est définie par :

$$\bullet \left(T^{(i,j)}\right)_{k,k} = 1 \text{ si } k \neq i \text{ et } k \neq j, \quad \left(T^{(i,j)}\right)_{i,j} = \left(T^{(i,j)}\right)_{j,i} = 1 \text{ et } \left(T^{(i,j)}\right)_{k,l} = 0, \text{ sinon.}$$

On note $P^{(1)} = T^{(1,i)} \Rightarrow \det(P^{(1)}) = \pm 1 \Rightarrow P^{(1)}$ inversible.

Le système est alors remplacé par $P^{(1)} A^{(1)} X = P^{(1)} b$.

On note $\alpha_{ij}^{(1)}$ les éléments de $P^{(1)} A^{(1)}$. On a alors

$$\alpha_{11}^{(1)} = a_{11}^{(1)} \neq 0, \alpha_{i1}^{(1)} = a_{i1}^{(1)}, \alpha_{k1}^{(1)} = a_{k1}^{(1)} \text{ pour } k \neq i, 1.$$

On multiplie le système par la matrice élémentaire $E^{(1)}$ définie par :

$$\bullet \left(E^{(1)}\right)_{l,l} = 1, \left(E^{(1)}\right)_{i,1} = \frac{-\alpha_{i1}^{(1)}}{\alpha_{11}^{(1)}} \text{ si } i \neq 1, \left(E^{(1)}\right)_{k,1} = 0 \text{ sinon.}$$

$$\Rightarrow \det(E^{(1)}) = 1 \Rightarrow E^{(1)} \text{ est inversible}$$

Le système est alors remplacé par : $E^{(1)} P^{(1)} A^{(1)} X = E^{(1)} P^{(1)} b$

On note $A^{(2)} = A^{(1)} P^{(1)} A^{(1)}$.

Si $A^{(2)} = (a_{ij}^{(2)})_{i,j=1,\dots,n}$, elle vérifie $a_{1,1}^{(2)} = \alpha_{1,1}^{(1)}$, $a_{k,1}^{(2)} = 0$, pour $k \neq 1$.

Notons au passage que la matrice $A^{(2)}$ est nécessairement inversible, puisque

$$\det A^{(2)} = \underbrace{\det E^{(1)}}_{=1} \times \underbrace{\det P^{(1)}}_{=\pm 1} \times \det A = \pm \det A$$

De manière générale, soit $A^{(k)}$ vérifiant $a_{p,q}^{(k)} = 0$ pour $p > q$ et $q < k$.

On choisit un pivot $a_{i,k}^{(k)}$ pour $k \leq i \leq n$ non nul. On multiplie à gauche par la matrice $P^{(k)} = T^{(k,i)}$ où $i > k$. Soient $\alpha_{i,j}^{(k)}$ les termes de $P^{(k)} A^{(k)}$.

On multiplie ensuite par la matrice élémentaire $E^{(k)}$ définie par :

$$(E^{(k)})_{i,i} = 1, (E^{(k)})_{i,k} = \frac{-\alpha_{i,k}^{(k)}}{\alpha_{k,k}^{(k)}} \text{ si } i > k, (E^{(k)})_{i,j} = 0 \text{ sinon.}$$

On obtient la matrice $A^{(k+1)} = E^{(k)} P^{(k)} A^{(k)}$.

Théorème

Soit A une matrice carrée inversible. Il existe au moins une matrice inversible M telle que MA soit triangulaire supérieure.

Preuve

$$\text{On a : } MA = A^{(n)} = E^{(n-1)} P^{(n-1)} A^{(n-1)} = E^{(n-1)} P^{(n-1)} \dots E^{(1)} P^{(1)} A$$

$$\text{d'où, } M = E^{(n-1)} P^{(n-1)} \dots E^{(1)} P^{(1)}.$$

Remarque:

Le nombre d'opérations nécessaires pour la résolution du système linéaire

$AX = b$ par la méthode de Gauss est de l'ordre de $\frac{2n^3}{3}$ opérations élémentaires

L'algorithme de Gauss

On pose $A^{(1)} = A$ i.e. $a_{ij}^{(1)} = a_{ij}$ pour $i, j = 1, \dots, n$;

pour $k = 1, \dots, n-1$

pour $i = k+1, \dots, n$

$$l_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}$$

pour $j = k+1, \dots, n$

$$a_{ij}^{(k+1)} = a_{ij}^{(k)} - l_{ik} a_{kj}^{(k)}$$

Les termes $a_{kk}^{(k)}$ sont appelés pivots et doivent être non nuls.

pour $k = 1, \dots, n-1$, $A^{(k+1)}$ possède $n-k$ lignes et colonnes.

Exemple 1

Résoudre par la méthode de Gauss, le système linéaire suivant :

$$(SL_1) \begin{cases} -2x_2 & -12x_3 & -x_4 = 2 \\ 4x_1 & +2x_2 & -2x_3 & +8x_4 = 2 \\ -4x_1 & -2x_2 & +3x_3 & -7x_4 = -9 \\ & +x_2 & & +4x_4 = 2 \end{cases}$$

$$b = \begin{pmatrix} 2 \\ 2 \\ -9 \\ 2 \end{pmatrix} \quad \text{et} \quad A = \begin{pmatrix} 0 & -2 & -12 & -1 \\ 4 & 2 & -2 & 8 \\ -4 & -2 & 3 & -7 \\ 2 & 1 & 0 & 4 \end{pmatrix} = A^{(1)}$$

1^{ère} étape

$$P^{(1)} = \begin{pmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \quad \Longrightarrow \quad P^{(1)} A^{(1)} = \begin{pmatrix} 4 & 2 & -2 & 8 \\ 0 & -2 & -12 & -1 \\ -4 & -2 & 3 & -7 \\ 2 & 1 & 0 & 4 \end{pmatrix}$$

$$E^{(1)} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ -\frac{1}{2} & 0 & 0 & 1 \end{pmatrix} \quad \Longrightarrow \quad A^{(2)} = E^{(1)} P^{(1)} A^{(1)} = \begin{pmatrix} 4 & 2 & -2 & 8 \\ 0 & -2 & -12 & -1 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 0 \end{pmatrix}$$

2^{ème} étape

$$P^{(2)} = E^{(2)} = I \implies A^{(3)} = E^{(2)} P^{(2)} A^{(2)} = \begin{pmatrix} 4 & 2 & -2 & 8 \\ 0 & -2 & -12 & -1 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 0 \end{pmatrix}$$

3^{ème} étape

$$P^{(3)} = I \quad \text{et}$$

$$E^{(3)} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & -1 & 1 \end{pmatrix} \implies A^{(4)} = \underbrace{E^{(3)} P^{(3)} A^{(3)}}_{MA} = \begin{pmatrix} 4 & 2 & -2 & 8 \\ 0 & -2 & -12 & -1 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & -1 \end{pmatrix}$$

Matrice triangulaire supérieure

Pour trouver la solution du système linéaire initial, par la méthode de remontée, on doit effectuer les transformations précédentes sur le second membre b en même temps que A .

D'où, si on pose $b^{(1)} = b$, on aura:

$$b^{(2)} = E^{(1)} P^{(1)} b^{(1)} = \begin{pmatrix} 2 \\ 2 \\ -7 \\ 1 \end{pmatrix}, \quad b^{(3)} = b^{(2)}, \quad b^{(4)} = E^{(3)} b^{(3)} = \begin{pmatrix} 2 \\ 2 \\ -7 \\ 8 \end{pmatrix}$$

En fin, on a

$$(SL_1) \begin{cases} -2x_2 - 12x_3 - x_4 = 2 \\ 4x_1 + 2x_2 - 2x_3 + 8x_4 = 2 \\ -4x_1 - 2x_2 + 3x_3 - 7x_4 = -9 \\ + x_2 + 4x_4 = 2 \end{cases} \iff (\overline{SL}_1) \begin{cases} 4x_1 + 2x_2 - 2x_3 + 8x_4 = 2 \\ -2x_2 - 12x_3 - x_4 = 2 \\ x_3 + x_4 = -7 \\ - x_4 = 8 \end{cases}$$

et par la méthode de remontée on déduit la solution de (SL_1) :

$$x_4 = -8, \quad x_3 = 1, \quad x_2 = -3, \quad x_1 = \frac{37}{2}.$$

Exemple 2

Considérons le système linéaire suivant :

$$(SL_2) \begin{cases} 10^{-6} x_1 + x_2 = 1 \\ x_1 + x_2 = 2 \end{cases}$$

et supposons qu'on fasse les calculs à 10^{-6} près, alors:

- la solution **exacte** de (SL_2) est

$$\begin{cases} x_1 = \frac{1}{1-10^{-6}} \cong 1,000001 \cong 1 \text{ (à } 10^{-6} \text{ près)} \\ x_2 = \frac{10^6 - 2}{10^6 - 1} \cong 0,999998 \cong 1 \text{ (à } 10^{-6} \text{ près)} \end{cases}$$

- On peut prendre le nombre $a_{11} = 10^{-6}$ comme pivot puisqu'il n'est pas nul, ce qui conduit après élimination au système linéaire:

$$(SL_{2,1}) \begin{cases} 10^{-6} x_1 + x_2 = 1 \\ (1 - 10^6) x_2 = 2 - 10^6 \end{cases}$$

dont la solution trouvée (à 10^{-6} près) en effectuant une remontée est:

$$x_2 = 0,999998 \cong 1, \quad \text{et} \quad x_1 \cong 0,000001 \cong 0.$$

qui constitue une **mauvaise approximation** de la solution exacte.

- Par contre, si l'on commence par permuter les deux équations de (SL_2) pour obtenir le plus grand pivot en valeur absolue, on est conduit au système suivant:

$$\begin{cases} x_1 + x_2 = 2 \\ 10^{-6} x_1 + x_2 = 1 \end{cases} \quad \text{qui après élimination devient}$$
$$(SL_{2,2}) \begin{cases} x_1 + x_2 = 2 \\ (1 - 10^{-6})x_2 = 1 - 2 \cdot 10^{-6} \end{cases}$$

dont la solution trouvée (à 10^{-6} près) en effectuant une remontée est:

$$x_2 = 0,999998 \cong 1, \quad \text{et} \quad x_1 \cong 1,000001 \cong 1.$$

Dans ce cas, le résultat est **satisfaisant**.

- L'exemple 2 montre l'effet désastreux des *erreurs d'arrondi* qui proviennent de la division par des pivots "trop petits" .
- C'est pourquoi, il est recommandé d'utiliser au début de chaque étape de la factorisation une des stratégies suivantes sur le choix du pivot:

stratégie du pivot partiel: le pivot est l'un des éléments

$$a_{pk}^{(k)}, \quad k \leq p \leq n, \quad \text{vérifiant} \quad \left| a_{pk}^{(k)} \right| = \max_{k \leq i \leq n} \left| a_{ik}^{(k)} \right|$$

stratégie du pivot total: le pivot est l'un des éléments

$$a_{pq}^{(k)}, \quad k \leq p, q \leq n, \quad \text{vérifiant} \quad \left| a_{pq}^{(k)} \right| = \max_{k \leq i, j \leq n} \left| a_{ij}^{(k)} \right|$$

L'algorithme de Gauss avec stratégie de pivot partiel

pour $k = 1, \dots, n$

pour $i = k + 1, \dots, n$

Trouver r telque $|a_{ik}^{(k)}| = \max_{r=k, \dots, n} |a_{rk}^{(k)}|$

Echanger la ligne k et la ligne r ,

$$l_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}$$

pour $j = k + 1, \dots, n$

$$a_{ij}^{(k+1)} = a_{ij}^{(k)} - l_{ik} a_{kj}^{(k)}$$

L'algorithme de Gauss avec stratégie de pivot total

pour $k = 1, \dots, n$

pour $i = k + 1, \dots, n$

Trouver p, q tels que $|a_{pq}^{(k)}| = \max_{i, j=k, \dots, n} |a_{ij}^{(k)}|$

Echanger la ligne k et la ligne p et la colonne k par la colonne q ,

$$l_{ik} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}$$

pour $j = k + 1, \dots, n$

$$a_{ij}^{(k+1)} = a_{ij}^{(k)} - l_{ik} a_{kj}^{(k)}$$

Donnons à présent quelques propriétés essentielles des matrices de permutation $P^{(k)}$ et des matrices d'élimination $E^{(k)}$ intervenant dans la méthode de Gauss. Notons pour tout, $1 \leq k \leq n-1$:

$$P^{(k)} = \begin{pmatrix} 1 & 0 & \cdots & \cdots & \cdots & \cdots & 0 \\ 0 & 1 & \cdots & 0 & \cdots & \cdots & \vdots \\ \vdots & \cdots & 0 & \vdots & 1 & \bigcirc & \vdots \\ \vdots & \cdots & \cdots & 1 & \cdots & \cdots & \vdots \\ \vdots & \cdots & 1 & \cdots & 0 & \cdots & \vdots \\ \vdots & \cdots & \bigcirc & \vdots & \cdots & \ddots & 0 \\ 0 & \cdots & \cdots & 0 & \cdots & \cdots & 1 \end{pmatrix} \begin{matrix} \leftarrow k \\ \\ \leftarrow i_k \end{matrix}$$

$k \leq i_k, i_k : \text{ligne pivot.}$

$\begin{matrix} \uparrow & \uparrow \\ k & i_k \end{matrix}$

et

$$E^{(k)} = \begin{pmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \bigcirc \\ & & & 1 & \\ & & & -\ell_{k+1,k} & \ddots \\ \bigcirc & & \vdots & & \ddots \\ & & -\ell_{nk} & & 1 \end{pmatrix}, \quad \text{où } \ell_{ik} \equiv -E_{ik}^{(k)} = \frac{a_{ik}^{(k)}}{a_{kk}^{(k)}}, \quad k+1 \leq i \leq n$$

Propriétés

- 1) La matrice de permutation $P^{(k)}$ est symétrique (${}^tP^{(k)} = P^{(k)}$) et orthogonale (${}^tP^{(k)} = (P^{(k)})^{-1}$), donc $(P^{(k)})^2 = I$.
- 2) La matrice d'élimination $E^{(k)}$ est inversible et son inverse est donné par:

$$(E^{(k)})^{-1} = \begin{pmatrix} 1 & & & & & \\ & \ddots & & & & \\ & & 1 & & & \\ & & & 1 & & \circ \\ & & & & 1 & \\ & & \circ & \ell_{k+1,k} & \ddots & \\ & & & \vdots & \ddots & \\ & & & \ell_{nk} & \ddots & 1 \end{pmatrix}$$

Factorisation LU d'une matrice

Si dans la méthode de Gauss, on n'effectue aucune permutation, alors

$A^{(n)} = E^{(n-1)} E^{(n-2)} \dots E^{(1)} A$, où $A^{(n)}$ est triangulaire supérieure et la matrice $E^{(n-1)} E^{(n-2)} \dots E^{(1)}$ est triangulaire inférieure, inversible.

On pourra donc décomposer A sous la forme : $A = LU$, avec

- $U = A^{(n)}$: est triangulaire supérieure (Upper).
- $L = \left(E^{(n-1)} \dots E^{(1)}\right)^{-1} = \left(E^{(1)}\right)^{-1} \dots \left(E^{(n-1)}\right)^{-1}$: est triangulaire inférieure (Lower).

Par un simple calcul, on peut montrer que :
$$L_{ij} = \begin{cases} 0, & \text{pour } i < j \\ 1, & \text{pour } i = j \\ \frac{\alpha_{ij}^{(j)}}{\alpha_{jj}^{(j)}}, & \text{pour } i > j \end{cases}$$

Comment calculer L et U?

Pour une matrice quelconque de dimension n :

Les éléments de L et U vérifient:

$$(S) \quad \sum_{r=1}^{\min(i,j)} l_{ir} u_{rj} = a_{ij}, \quad i, j = 1, \dots, n$$

Ce système est sous-déterminé: n^2 équations et $n^2 + n$ inconnues, la factorisation LU n'est pas unique

En fixant la valeur 1 pour les n éléments diagonaux de L, (S) est résolu avec l'algorithme de Gauss

Proposition

Soit A une matrice carrée d'ordre n , inversible.

La factorisation LU de A existe **si et seulement si** tous ses mineurs principaux d'ordre $k=1,2,\dots,n$, sont non nuls.

Remarque : Un intérêt majeur de la factorisation LU d'une matrice est de pouvoir résoudre plusieurs systèmes linéaires correspondant à la même matrice A . Pour cela, il suffit de conserver l'expression des matrices L et U une fois celles-ci calculées et de résoudre ensuite chaque système linéaire $Ax = b$ en résolvant deux systèmes linéaires triangulaires :

$Ly = b$ (par la méthode de descente),

puis

$Ux = y$ (par la méthode de remontée).

L'algorithme de descente:

$$y_1 = \frac{1}{l_{11}} b_1,$$

$$y_i = \frac{1}{l_{ii}} (b_i - \sum_{j=1}^{i-1} l_{ij} y_j), \quad i = 2, \dots, n$$

Nombre d'opérations dans l'algorithme de descente:

Pour y_i on effectue $i-1$ sommes, $i-1$ produits et 1 division, le nombre total d'opérations est donc n^2 .

L'algorithme de remontée:

$$x_n = \frac{1}{u_{nn}} y_n,$$

$$x_i = \frac{1}{u_{ii}} \left(y_i - \sum_{j=i+1}^n u_{ij} x_j \right), \quad i = n-1, \dots, 1$$

De même le nombre d'opérations dans l'algorithme de remontée est : n^2

Définition: Matrice définie positive

Soit $A \in M_n(\mathbb{R})$ une matrice symétrique. Alors, A est dite **définie positive**, si elle vérifie les deux propriétés suivantes:

- 1) $\forall x \in \mathbb{R}^n, \quad (Ax, x) \geq 0$
- 2) $\forall x \in \mathbb{R}^n, \quad \text{on a : } (Ax, x) = 0 \Leftrightarrow x = 0$

Autrement dit, une matrice symétrique A est définie positive ssi :

$$\forall x \in \mathbb{R}^n \setminus \{0\}: \quad (Ax, x) > 0.$$

Définition: Matrice à diagonale strictement dominante

Une matrice carrée A est dit à **diagonale strictement dominante** si :

$$\text{pour tout } i = 1, \dots, n : \quad |a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|$$

Remarque :

Une matrice symétrique réelle à diagonale strictement dominante ayant des coefficients diagonaux positifs est symétrique définie positive.

Proposition

Si A symétrique définie positive alors A se décompose sous la forme : $A=LU$

Méthode de Cholesky

Dans cette section, on considère une matrice A **symétrique** et **définie positive**.

Théorème

Soit A une matrice symétrique définie positive. Alors, il existe au moins une matrice réelle triangulaire inférieure B telle que:

$$A = B^t B.$$

Si de plus, on impose que les éléments diagonaux de B soient positifs alors cette factorisation est unique.

Remarque : La méthode de Cholesky, pour la résolution d'un système linéaire à matrice symétrique et définie positive: $Ax = b$, consiste à calculer la factorisation de cholesky : $A = B^t B$ puis à résoudre successivement les deux systèmes linéaires (à matrices triangulaires) suivants:

$$By = b \quad (\text{par la méthode de descente}),$$

puis

$${}^t Bx = y \quad (\text{par la méthode de remontée}).$$

Algorithme de calcul de B colonne par colonne :

pour $j = 1$ à n **faire**

Début

$$b_{jj} = \sqrt{a_{jj} - \sum_{k=1}^{j-1} b_{jk}^2}$$

pour $i = j + 1$ à n **faire**

$$b_{ij} = \frac{1}{b_{jj}} \left(a_{ij} - \sum_{k=1}^{j-1} b_{ik} b_{jk} \right)$$

Fin

Fin

Il faut noter que pour calculer la colonne j de B , on commence par calculer le terme diagonal b_{jj} , ensuite les termes b_{ij} pour $i \geq j + 1$.

Algorithme de calcul de B ligne par ligne :

pour $i = 1$ à n **faire**

Début

pour $j = 1$ à $i - 1$ **faire**

Début

$$b_{ij} = \frac{1}{b_{jj}} \left(a_{ij} - \sum_{k=1}^{j-1} b_{ik} b_{jk} \right)$$

Fin

$$b_{ii} = \sqrt{a_{ii} - \sum_{k=1}^{i-1} b_{ik}^2}$$

Fin

Il faut noter que pour calculer la ligne i de B , on commence par calculer les termes b_{ij} pour $1 \leq j \leq i - 1$, ensuite le terme diagonal b_{ii} .

Remarque:

Le nombre d'opérations nécessaires pour la résolution du système linéaire $A X = b$ par la méthode de Cholesky est de l'ordre de $\frac{n^3}{3}$ opérations élémentaires.

Comment résoudre un système tridiagonal

- Dans de nombreuses applications on doit résoudre un système dont la matrice est **tridiagonale**.
- Une matrice A est tridiagonale si les seuls éléments non nuls sont sur la diagonale principale et sur les premières sur- et sous-diagonales.
- Si la factorisation LU de A existe, les matrices sont bidiagonales (inférieure et supérieure respectivement).

On note:

- ▶ a_i les éléments diagonaux, e_i et c_i les éléments sous et sur-diagonaux (respectivement) de A ,
- ▶ β_i les éléments sous-diagonaux de L ,
- ▶ α_i les éléments sur-diagonaux de U .

- En écrivant $A = LU$, on a

$$\alpha_1 = a_1, \quad \beta_i = \frac{e_i}{\alpha_{i-1}}, \quad \alpha_i = a_i - \beta_i c_{i-1}, \quad i = 2, \dots, n.$$

- Il est facile de résoudre les deux systèmes bidiagonaux

$$L y = b \quad \text{et} \quad L x = y$$

par:

$$y_1 = b_1, \quad y_i = b_i - \beta_i y_{i-1}, \quad i = 2, \dots, n.$$

et

$$x_n = \frac{y_n}{\alpha_n}, \quad x_i = (y_i - c_i x_{i+1}) / \alpha_i, \quad i = n-1, \dots, 1.$$

Cette technique est l'algorithme de **Thomas**. Son coût est de l'ordre de n opérations.

En résumé (pour les méthodes directes):

- La *factorisation LU* de A consiste à calculer une matrice triangulaire inférieure L et une matrice triangulaire supérieure U telles que $A=LU$.
- La factorisation LU , quand elle existe, n'est pas unique. On peut la rendre unique en fixant (par exemple) les valeurs des éléments diagonaux de L à 1. C'est la *factorisation de Gauss*.
- La factorisation de Gauss existe et est unique ssi les mineurs principaux de A d'ordre 1 à $n-1$ sont tous non nuls.
- Quand un pivot est nul, on peut échanger des lignes convenablement choisies. C'est la *stratégie du pivot*.

En résumé (pour les méthodes directes):

- Le calcul de la factorisation de Gauss nécessite de l'ordre de $2n^3/3$ opérations en général et seulement de l'ordre de n opérations dans le cas d'un système tridiagonal.
- Pour les matrices symétriques définies positives, on peut utiliser la factorisation de Cholesky $A = B^T B$ où B est une matrice triangulaire inférieure. Le coût du calcul est alors de l'ordre de $n^3/3$ opérations.
- La sensibilité du résultat aux perturbations des données dépend du conditionnement de A .

- Remarques:
- La factorisation de Gauss est à la base de nombreuses commandes MATLAB:
 - $[L,U]=lu(A)$
 - Inv qui permet le calcul de l'inverse d'une matrice
 - $\backslash$ donne la solution x de $Ax=b$ en écrivant $A\backslash b$

- Dans MATLAB, $[L,U,P]=\text{lu}(A)$ pour la factorisation de Gauss avec pivot.
- Le programme `lu` de MATLAB active automatiquement la stratégie de pivot quand un pivot est nul ou très petit.

Remarque: Calculer un déterminant

La factorisation LU permet de calculer $\det(A)$ avec environ $O(n^3)$ opérations. En effet,

$$\det(A) = \det(L)\det(U) = \prod_{i=1}^n u_{ii}.$$

La factorisation de Cholesky:

- Grâce à la symétrie, on ne stocke que la partie inférieure de A et on peut ranger les coefficients de B au même endroit.
- On effectue la factorisation de Cholesky dans MATLAB en entrant $R = \text{chol}(A)$, où R est la matrice triangulaire supérieure B^T .

- La commande `spdiags` de MATLAB permet de construire une matrice tridiagonale T .
- T est définie de manière creuse, seuls les éléments non nuls sont stockés.
- Une matrice d'ordre n est *creuse* si elle a un nombre de termes non nuls de l'ordre de n . On appelle *profil* d'une matrice creuse l'ensemble de ses coefficients non nuls.
- Quand on utilise « `\` », MATLAB détecte le type de matrice et sélectionne l'algorithme de résolution le plus approprié.
- Si elle est tridiagonale et stockée sous forme creuse, c'est l'algorithme de Thomas qui est utilisé.

Partie III : Méthodes itératives

1. Principe des méthodes itératives
2. Convergence des méthodes itératives
3. Méthodes itératives classiques
 - 3.1 Méthode de Jacobi
 - 3.2 Méthode de Gauss-Seidel
 - 3.3 Méthode de Relaxation
4. Comparaison entre différentes méthodes

Pourquoi utiliser les méthodes itératives

On cherche à résoudre une équation de la forme : $Ax = b$.

Les méthodes **directes** fournissent la solution $\tilde{x}$ en un nombre fini d'opérations. Mais :

- si la taille du système est élevée, le nombre d'opérations est important,
or les erreurs de calcul dépendent directement du nombre de calculs.
- elles utilisent des propriétés mathématiques nécessitant un calcul exact,
il est difficile de tenir compte des erreurs de calcul dans ce processus

Donc le résultat n'est **jamais rigoureusement égal à $\tilde{x}$** . Il peut même en être **très différent**.

Principe des méthodes itératives

On suppose que A se décompose sous la forme :
 $A = M - N$, où M est une matrice inversible.

$$A x = b \Leftrightarrow M x = N x + b$$

• Soit $x^{(0)}$ un vecteur initial, on définit la suite :

$$x^{(k+1)} = M^{-1}(N x^{(k)} + b)$$

En posant $C = M^{-1}N$, on a l'écriture équivalente :

$$(2) \quad x^{(k+1)} = C x^{(k)} + d \quad \text{avec} \quad d = M^{-1}b.$$

On dit que C est la matrice de la méthode itérative (2).

Quelques méthodes itératives

Soit A une matrice d'ordre n . On définit :

- la matrice diagonale $D = (d_{ij})$ tq : $d_{ij} = \begin{cases} a_{ij} & ; \text{si } i = j \\ 0 & ; \text{sinon} \end{cases}$
- la matrice triang - sup $U = (u_{ij})$ tq : $u_{ij} = \begin{cases} -a_{ij} & ; \text{si } i < j \\ 0 & ; \text{sinon} \end{cases}$
- la matrice triang - inf $L = (l_{ij})$ tq : $l_{ij} = \begin{cases} -a_{ij} & ; \text{si } i > j \\ 0 & ; \text{sinon} \end{cases}$

C'est-à-dire

$$A = \begin{pmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & a_{ij} & \vdots \\ a_{n1} & \cdots & a_{nn} \end{pmatrix}$$

$$D = \begin{pmatrix} a_{11} & & 0 \\ & \ddots & \\ 0 & & a_{nn} \end{pmatrix}$$

$$U = - \begin{pmatrix} 0 & a_{ij} & \\ & \ddots & \\ 0 & & 0 \end{pmatrix}_{i < j}$$

$$L = - \begin{pmatrix} 0 & & 0 \\ a_{ij} & \ddots & \\ & \ddots & 0 \end{pmatrix}_{i > j}$$

Alors, $A = D - L - U$

Convergence des méthodes itératives

Connaissant C , comment savoir si la suite va converger ?

Théorème

Soit $C \in M_n(\mathbb{R})$ et $d \in \mathbb{R}^n$.

La suite définie par :
$$\begin{cases} x^{(0)} \text{ donné} \\ x^{(k+1)} = C x^{(k)} + d \end{cases}$$

converge, pour tout choix de $x^{(0)}$,

vers un élément $\tilde{x} \in \mathbb{R}^n$ solution du système linéaire

$(I - C)x = d$ si et seulement si $\rho(C) < 1$.

Cas particulier :

Soit A une matrice **symétrique** et **définie positive**, décomposée en $A = M - N$ où M est inversible, et posons:

$$C = M^{-1}N = I - M^{-1}A$$

Si la matrice (symétrique) $M + {}^tN$ est **définie positive** alors

$$\rho(C) < 1$$

est donc la méthode itérative définie par:

$$x^{(k+1)} = C x^{(k)} + d$$

converge.

Conclusion

Soit A une matrice, pour résoudre le système d'équations $Ax = b$,
il faut décomposer $A = M - N$ de tel façon que :

- M soit inversible.
- l'une des deux conditions suivantes soit vérifiée
 - $C = M^{-1} N$ ait un rayon spectral < 1 (le plus petit possible).
 - Si A est symétrique et définie positive, $M + {}^t N$ soit aussi définie positive.

Le problème est alors, comment choisir M et N ?

Méthode de Jacobi

La méthode itérative de **Jacobi** s'écrit : Pour $x^{(0)}$ donné;

$$D x^{(k+1)} = (L + U) x^{(k)} + b, k \geq 0.$$

D est inversible ssi tous les éléments diagonaux de A sont non nuls, et dans ce cas on a :

$$x^{(k+1)} = \underbrace{D^{-1}(L + U)}_J x^{(k)} + \underbrace{D^{-1}b}_{d_J}, k \geq 0.$$

- La matrice $J = D^{-1}(L + U)$ est appelée **matrice de Jacobi**.
- On a convergence ssi $\rho(J) < 1$.

Conditions suffisantes de convergence de Jacobi

Théorème

Si A est une matrice à **diagonale strictement dominante**, alors la méthode de **Jacobi converge** pour tout choix du vecteur initial $x^{(0)}$.

Cas des matrices symétriques

Théorème

Si A et $2D-A$ sont symétriques et définies positives, alors la méthode de **Jacobi converge**.

Méthode de Gauss-Seidel

La méthode itérative de **Gauss - Seidel** s'écrit : Pour $x^{(0)}$ donné;

$$x^{(k+1)} = (D - L)^{-1} U x^{(k)} + (D - L)^{-1} b, k \geq 0.$$

$D - L$: est triangulaire inférieure, elle est inversible **ssi** tous les éléments diagonaux de A sont non nuls.

A chaque itération, on résoud le système :

$$(D - L)x^{(k+1)} = U x^{(k)} + b \quad \text{sans calculer la matrice } (D - L)^{-1}.$$

- La matrice $L_1 = (D - L)^{-1} U$ est appelée matrice de **Gauss - Seidel**.
- On a convergence **ssi** $\rho(L_1) < 1$.

Conditions suffisantes de convergence de Gauss-Seidel

Théorème

Si A est une matrice à **diagonale strictement dominante**, alors la méthode de **Gauss - Seidel** est **convergente** quel que soit le vecteur initial $x^{(0)}$.

Cas des matrices symétriques

Théorème

Si A est une matrice symétrique et définie positive, alors la méthode de **Gauss - Seidel** est **convergente** quel que soit le vecteur initial $x^{(0)}$.

Comparaison entre la méthode de Jacobi et de Gauss-Seidel

Théorème

Soit A une matrice **tridiagonale**. Alors les rayons spectraux des matrices de Jacobi et de Gauss - Seidel sont liés par la relation :

$$\rho(L_1) = (\rho(J))^2.$$

- Les deux méthodes convergent ou divergent simultanément.
- Lorsqu'elles convergent la méthode de Gauss - Seidel converge plus rapidement.

Méthode de Relaxation

On introduit un paramètre réel $\omega \neq 0$ et on prend :

$$\begin{cases} M = \frac{D}{\omega} - L, \\ N = \frac{1-\omega}{\omega} D + U. \end{cases}$$

M est inversible ssi tous les éléments diagonaux de A sont non nuls.

On résoud pour $x^{(0)}$ donné;

$$\left(\frac{D}{\omega} - L \right) x^{(k+1)} = \left(\frac{1-\omega}{\omega} D + U \right) x^{(k)} + b, \quad k \geq 0.$$

- Pour $\omega = 1$, on retrouve la méthode de Gauss - Seidel.
- Pour $\omega > 1$, la méthode est dite de sur - relaxation.
- Pour $\omega < 1$, la méthode est dite de sous - relaxation.

la matrice $L_\omega = \left(\frac{D}{\omega} - L \right)^{-1} \left(\frac{1-\omega}{\omega} D + U \right)$, est la matrice de **relaxation**

Condition suffisante de convergence de la méthode de relaxation

Proposition

Si A est symétrique et définie positive alors la méthode de **relaxation** converge pour $\omega \in]0,2[$.

Condition nécessaire de convergence de la méthode de relaxation

Théorème

- Le rayon spectral de L_ω vérifie : $\rho(L_\omega) \geq |\omega - 1|$.
- La méthode de relaxation diverge pour tout $\omega \in \mathbb{R} \setminus [0,2]$.

Comparaison entre les méthodes de Jacobi et de Relaxation

Théorème

Soit A une matrice **tridiagonale**. On suppose que toutes les valeurs propres de la matrice de Jacobi J sont réelles et strictement inférieures à 1 en valeur absolue. Alors :

- Les deux méthodes (de Jacobi et de Relaxation) convergent ou divergent simultanément.
- De plus, il existe une valeur optimale de ω notée ω_0 donnée par :

$$\omega_0 = \frac{2}{1 + \sqrt{1 - (\rho(J))^2}}$$

pour laquelle $\rho(L_\omega)$ est minimal, c'est à dire

$$\forall \omega \in]0, 2[, \quad \rho(L_\omega) \geq \rho(L_{\omega_0}) = \omega_0 - 1.$$