

Alphabets et langages

Définitions :

1. Alphabet : Ensemble **fini** de symboles, noté en général par Σ

- Alphabet Latin $\Sigma = \{a, b, c, \dots, z\}$
- Alphabet binaire $\Sigma = \{0, 1\}$
- $\Sigma = \{\text{rouge}, \text{noir}, 0, 1, a\}$

2. Mot ou chaîne : Séquence de symboles de l'alphabet. Noté w .

- $w_1 = \text{voiture}$; $w_2 = \text{voyage}$ deux mots définies sur l'alphabet Latin
- $w_1 = 00101$; $w_2 = 101101$ sont deux mots définies sur l'alphabet binaire.
- $w_1 = \text{noir}01\text{rouge}$; $w_2 = 10a\text{noir}$: sont deux mots définies sur l'alphabet $\Sigma = \{\text{rouge}, \text{noir}, 0, 1, a\}$

3. Taille d'un mot : $|w|$ = nombre de symboles constituant le mot.

- $|\text{rouge}| = 5$ en considérant l'alphabet Latin
- $|001| = 3$ en considérant l'alphabet binaire
- $|\text{rouge}| = 1$ en considérant l'alphabet $\Sigma = \{\text{rouge}, \text{noir}, 0, 1, a\}$

4. Chaîne vide : notée ε s'il n'appartient pas à l'alphabet ou ε
 $|\varepsilon| = 0$.

5. Sous chaîne : x est une sous chaîne de w si il existe y et z (chaînes sur le même alphabet). Tel que $w = y x z$.

6. **Préfixe** : x est un préfixe de w si il existe y tel que: $w = x y$.

7. **Suffixe** : x est un suffixe de w si il existe y tel que $w = y x$.

- $x = \text{voit}$ est un *préfixe* de $w = \text{voiture}$, car il existe $y = \text{ure}$ tel que $w = \text{voit ure} = x y$
- $x = \text{ture}$ est un *suffixe* de $w = \text{voiture}$, car il existe $y = \text{voi}$ tel que $w = \text{voi ture} = yx$

1. Concaténation : soient u et v deux mots définis sur l'alphabet Σ , tel que :

$$u = x_1 x_2 \dots x_n \quad v = y_1 y_2 \dots y_m$$

$$w = u.v = x_1 x_2 \dots x_n y_1 y_2 \dots y_m$$

Concaténation est non commutative

Propriétés :

- $|w| = |uv| = |u| + |v|$
- $\cdot$ *Est associative*

$\forall \varepsilon$ *est l'élément neutre pour la concaténation.* $\varepsilon x = x\varepsilon = x$

2. Facteur : soit u, v, w, t des mots définis sur Σ tel que $w = uv t$

- si $u = \varepsilon$ alors v est dit facteur gauche de w (ou préfixe).
- si $t = \varepsilon$ alors v est dit facteur droit de w (ou suffixe).
- si $u = t = \varepsilon$ alors w est un facteur de lui même.

3. Occurrence d'un symbole dans un mot :

$$|abaaba|_a = 4$$

4. Image (reverse) : $w = aabab \quad w^R = babaa$

- Si $x \in \Sigma$ alors $x^R = x$
- Si $w = xu$ alors $w^R = u^R x$

Monter que $(wu)^R = u^R w^R \quad \forall k/|u| \neq k$

Par induction sur la longueur de u .

- $|u|=1$, $(wu)^R = uw^R = u^R w^R$.
- Supposons que c'est vrai pour $k > 1$ et montrons le pour $n > k$.
- $u = tx$, avec $|u| \geq k$ et $|t| < k$, $x \in \Sigma$.
- $(wu)^R = (wt x)^R = x^R (wt)^R = x t^R w^R$, par HI, $|t| \leq k$.

$$= x^R t^R w^R = (tx)^R w^R = u^R w^R$$

Ensemble de mots choisis dans un alphabet.

♦ langage peut être infini mais il existe un nombre finie de symboles permettant de composer les mots de ce langage.

Σ^k = ensemble des mots de longueur k avec des symboles de Σ

Exemple : $\Sigma = \{0,1\}$

- $\Sigma^1 = \{0,1\}$
- $\Sigma^2 = \{00,01,10,11\}$
- $\Sigma^0 = \{\epsilon\}$

Σ^* : Ensemble de toute les séquences de taille fini défini sur Σ
 : Fermeture de l'alphabet.

$$\Sigma^* = \{\varepsilon\} \cup \Sigma^1 \cup \Sigma^2 \dots$$

$$\Sigma^+ = \Sigma^1 \cup \Sigma^2 \dots$$

$$\Sigma^+ \cup \{\varepsilon\} = \Sigma^*$$

Si Σ est un alphabet, et $L \subseteq \Sigma^$ alors L est un langage*

Un langage c'est un ensemble de mots appartenant à Σ^* et qui vérifie une propriété donnée :

$$L = \{w \in \Sigma^* \mid w \text{ possède la propriété } P\}$$

- Ensemble des mots anglais légales
- Ensemble de programmes C légales
- Ensemble des mots de l'alphabet binaire contenant un nombre de n de 0 suivie par le même nombre n de 1.

$$L = \{\varepsilon ; 01 ; 0011; 000111; \dots \}.$$

- Ensemble des mots de l'alphabet binaire ayant un même nombre de 0 et de 1.

$$L = \{\varepsilon ; 01 ; 10; 0101; 1001; \dots \}.$$

- Ensemble des mots de l'alphabet binaire tel que leur valeur est premier.

$$L = \{10; 11; 101; 111; 1011; \dots\}$$

- Le langage vide $L = \emptyset$;
- Le langage $\{\varepsilon\}$ contenant le mot vide.

Note: $\emptyset \neq \{\varepsilon\}$.

Note: L'alphabet Σ est un ensemble fini.

- Ensemble des palindromes sur l'alphabet $\Sigma = \{a,b\}$

$$L = \{w \in \Sigma^* \mid w = w^R\}$$

$$L = \{\varepsilon, aba, bab, a, b, \dots\}$$

- Σ^* est infinie et dénombrable.
- $L = L_1 \cup L_2 = \{w \in \Sigma^* \mid w \in L_1 \text{ ou } w \in L_2\}$
- $L = L_1 \cap L_2 = \{w \in \Sigma^* \mid w \in L_1 \text{ et } w \in L_2\}$

- Concaténation :

$$L = L_1 \cdot L_2 = L_1 L_2 = \{w \in \Sigma^* \mid \exists x, y, w = xy, x \in L_1, y \in L_2\}$$

- Fermeture de Kleene.

$$L^* = \{w \in \Sigma^* \mid w = w_1 w_2 \dots w_k, k \geq 0 \text{ et } w_1, w_2, \dots, w_k \in L\}$$

$$k = 0 \Rightarrow w = \varepsilon ; k = 1 \Rightarrow w \in L ;$$

Si L est un langage alors L^* désigne l'ensemble de toutes les chaînes de longueurs finies formées par concaténation de mots de L , où chaque mot peut être

utilisé de 0 à n fois, la chaîne vide est incluse.

- $L \cup M = M \cup L.$

Union est commutative.

- $(L \cup M) \cup N = L \cup (M \cup N).$

Union est associative.

- $(LM)N = L(MN).$

Concaténation est associative

Note: Concaténation n'est pas commutative, i.e.,

Il existe L et M tel que $LM \neq ML.$

Exemple :

- $L = \{aa, b\}$
- $L^* = \{\varepsilon, b, aa, bb, aab, baa, bbb, aaaa, aabb, baab, bbaa, bbbb, aaaab, aabaa, aabbb, baaaa, bbaab, bbbba, bbbbbb, \dots\}$

Note : $\emptyset^* = \{\varepsilon\} \neq \emptyset$

Exercice

Soit $\Sigma = \{0, 1\}$

$L = \{w \in \Sigma^* \mid w \text{ contient un nombre de 1 différent de nombre de 0.}\}$

Montrer que $L^* = \Sigma^*$

- $L(M \cup N) = LM \cup LN.$

Concaténation est distributive à gauche pour l'union.

- $(M \cup N)L = ML \cup NL.$

Concaténation est distributive à droite pour l'union.

- $L \cup L = L.$

Union est idempotent.

- $\emptyset^* = \{\varepsilon\}$, $\{\varepsilon\}^* = \{\varepsilon\}$

- $L^+ = LL^* = L^*L$, $L^* = L^+ \cup \{\varepsilon\}$

- $(L^*)^* = L^*$. Fermeture est idempotente

Il y a une différence?

Il faut faire la différence entre:

ε - la chaîne vide ("")

$\emptyset$ - l'ensemble vide({ })

$\{\varepsilon\}$ - l'ensemble qui contient tout simplement la chaîne vide.

Exercise

Completer

$$L^* \cup \{\epsilon\} = \underline{\hspace{2cm}}$$

$$L^+ \bullet \{\epsilon\} = \underline{\hspace{2cm}}$$

$$\{\epsilon\} \bullet \{\epsilon\} = \underline{\hspace{2cm}}$$

$$\emptyset \bullet L = \underline{\hspace{2cm}}$$

$$L^* \bullet L^* = \underline{\hspace{2cm}}$$

$$(L^*)^* = \underline{\hspace{2cm}}$$

$$L \bullet L^* = \underline{\hspace{2cm}}$$

$$\emptyset^* = \underline{\hspace{2cm}}$$

$$\{\epsilon\}^* = \underline{\hspace{2cm}}$$

Définition : langages formels

Tout sous ensemble de Σ^* dont les mots peuvent être définis de deux façons

Définition par propriété :

Modélisation formelle d'une description naturel d'un langage.

Exemple :

L_1 : {ensemble de mots définies sur {a,b} de longueur pair}

$$L_1 = \{w \in \{a,b\}^* / |w| = 2n ; n \geq 0\}$$

Définition réursive : Définition dans laquelle, un langage est définie sur lui même.

$$L_2 = \{w \in \Sigma^* \mid w = a \text{ ou } w = aw_1; w_1 \in L_2\} = \{a, aa, \dots, aaaa, \dots\}$$

$$L_3 = \{w \in \Sigma^* \mid w = \varepsilon \text{ ou } w = w_1w_2; |w_1| = 2 \text{ et } w_2 \in L_3\}$$

$$L_3 \equiv L_1$$

Expressions régulières :

$$L_4 = \{\varepsilon, x, xx, xxx, xxxx, \dots\}$$

soit $S = \{x\}$ alors $L_4 = S^*$ ou $L_4 = \{x\}^*$

Considérons l'étoile de la fermeture de Kleene appliquée à la lettre x .

$$x^*$$

- x^* indiquera une séquence quelconque de x qui peut être vide.
- $x^* = \varepsilon$ ou x ou xx ou $xxx \dots$

$$L_4 = \text{langage } (x^*)$$

- Considérons le langage

$$L = \{a, ab, abb, abbb, abbbb, \dots\}$$

Toutes les chaînes constitués par un a suivi d'un nombre quelconque de b

On peut noter : $L = \text{Langage}(ab^*)$

Langage dans lequel les mots sont la concaténation d'un a (a) initial avec un nombre quelconque de b (b^*).

Appliquons l'étoile de Kleene à toute la chaîne ab , on aura :

$$(ab)^* = \varepsilon \text{ ou } ab \text{ ou } abab \text{ ou } \dots$$

- Le langage définit par l'expression :

$$ab^*a$$

Ensemble de toutes les chaînes de a et de b qui ont au moins deux lettres, qui commencent et finissent par un a . et qui n'ont que des b ou rien à l'intérieur.

$$\text{langage } (ab^*a) = \{aa, aba, abba, abbba, \dots\}$$

Remarque :

Fausse description : Ensemble de tous les mots qui commencent et puis finissent par a et qui n'ont que des b (ou rien) entre eux.

Le mot a appartient a cette description.

- Le langage définit par l'expression :

$$a^*b^*$$

Ensemble de toutes les chaînes de a et de b *dans lesquelles les a 's viennent avant les b 's.*

$$\text{langage } (a^*b^*) = \{\varepsilon, a, b, aa, bb, ab, bb, aaa, abb, \dots\}$$

Remarque :

$$a^*b^* \neq (ab)^*$$

Le langage à droite contient $abab$ tandis que celui à gauche ne le contient pas

T définie sur $\Sigma = \{a, b, c\}$

$$T = \{a, c, ab, cb, abb, cbb, abbb, cbbb, abbbb, cbbbbb, \dots\}$$

- Tous les mots de T commencent avec un a ou un c ensuite ils sont suivis par un nombre quelconque éventuellement nulle de b .

$$\text{Symboliquement } T = \text{langage } ((a \cup c)b^*)$$

Exemple :

- Ensemble des chaînes de a et de b de longueur 3.

$$L = \text{lang } ((a \cup b)(a \cup b)(a \cup b))$$

- Ensemble des chaînes de a et de b de longueur quelconque

$$L = \text{lang}((a \cup b)^*)$$

Une *expression régulière* sur un alphabet Σ est une chaîne de caractère sur l'alphabet $\Sigma, (,), \cup, *, \emptyset$. Tel que :

1. Toute lettre de $\Sigma \cup \{\varepsilon\}$ et $\emptyset$ est une expression régulière
2. si r_1 et r_2 sont deux expressions régulières alors ;
 - (r_1)
 - $r_1 r_2$
 - $r_1 \cup r_2$
 - r_1^*

Sont des expressions régulières

3. Rien d'autre n'est une expression régulière.

Exemple 1 :

$$\Sigma = \{a, b\}$$

$$L = \{w \in \Sigma^* \mid w \text{ contient la sous chaîne } aa \}$$

$$R = (a \cup b)^* aa (a \cup b)^*$$

Exemple 2 :

$$\Sigma = \{a, b\}$$

$$L = \{w \in \Sigma^* \mid w \text{ ne contient pas 3 } b \text{ consécutifs} \}$$

$$R = (a \cup ba \cup bba)^* (\varepsilon \cup b \cup bb)$$

Théorème :

Un langage L est dit régulier si et seulement si il existe une expression régulière qui le génère.

Exemple :

$$\Sigma = \{a, b\}$$

$$L = \{w \in \Sigma^* \mid w \text{ contient un nombre paire de } a \text{ et un nombre pair de } b \}$$

$$R = (aa \cup bb \cup (ab \cup ba))(aa \cup bb)^*(ab \cup ba)^*$$

Propriétés

Étant donné deux langages réguliers L_1 et L_2

- $L_1 \cup L_2$: est un langage régulier
- $L_1 \cdot L_2$: est un langage régulier
- $\underline{L_1}^*$: est un langage régulier
- $\underline{L_1} = \Sigma^* \setminus L_1$: est un langage régulier
- $L_1 \cap L_2 = \underline{(\underline{L_1} \cup \underline{L_2})}$ est un langage régulier
- L^R : est un langage régulier
- $L_1 \setminus L_2$: est un langage régulier

Définition : Deux expressions régulières α et β sont dites équivalentes si $L(\alpha) = L(\beta)$

Autrement s'ils génèrent le même langage

Exemple :

Langage de tous les mots qui ont au moins 2 a's
peut être décrit par l'expression régulière :

$$(a \cup b)^*a (a \cup b)^*a (a \cup b)^*$$

Autre expression régulière

$$b^*ab^*a(a \cup b)^*$$

On peut noter :

$$(a \cup b)^*a (a \cup b)^*a (a \cup b)^* = b^*ab^*a(a \cup b)^*$$